מטלה בלמידת מכונה – עיבוד תמונה / ניתוח טקסט – מסמך הסבר

בסעיפים הבאים נתייחס לנקודות הבאות:

שאלות על המטלה 1
פרטים טכניים הנוגעים למטלה 1
הרשמה בטבלת המטלה (קישור מופיע במודל)..... 2
הסכמה להראות תוצרים..... 2
תאריך הגשת המטלה 2
תוצרי ההגשה 2
אופן ההגשה 3
מה עליכם לבצע במטלה?..... 4
חלק 1 – הקדמה, בתחילת המטלה (ניתן לצבור עד 15 נקודות בסעיף זה)..... 4
מדד האיכות..... 4
חלק 2 – feature engineering (ניתן לצבור עד 30 נקודות בסעיף זה) 4
חלק 3 – מימוש אלגוריתם למידה (ניתן לצבור עד 30 נקודות בסעיף זה) 4
חלק 4 – אימון - הפעלת ה- flow לפי הפרמטרים השונים (ניתן לצבור עד 10 נקודות בסעיף זה) 5
חלק 5 – חיזוי ושערוך איכות המודל על ה- test set (ניתן לצבור עד 10 נקודות בסעיף זה) 5
חלק 6 – הרחבה – סעיף בונוסים (ניתן לצבור עד 65 נקודות בסעיף זה)..... 5

שאלות על המטלה

- שאלות אישיות - נא לפנות במייל למרצים (בכותרת המייל כתבו: מטלה בלמידת מכונה)
- שאלות הבנה ותוכן - נא להשתמש בפורום הייעודי במודל (הוסיפו נושא חדש וכתבו את השאלה)

פרטים טכניים הנוגעים למטלה

קבצי data

- עליכם לבחור מטלה בניתוח טקסט או עיבוד תמונה ולבחור dataset ב- Kaggle (תבחרו משהו יחסית פשוט)
  - עבור מטלה בניתוח טקסט/עיבוד שפה טבעית (NLP) –
    - עליכם לבחור dataset מתוך ה- datasets בניתוח טקסט מ- Kaggle, דרך הקישור https://www.kaggle.com/datasets?tags=13204-NLP
      - למשל, dataset עבור סיווג אימיילים כ-spam או not-spam: https://www.kaggle.com/datasets/team-ai/spam-text-message-classification
  - עבור מטלה בעיבוד תמונה/ראיה ממוחשבת (Computer Vision) –
    - עליכם לבחור dataset מתוך ה- datasets בעיבוד תמונה מ- Kaggle, דרך הקישור https://www.kaggle.com/datasets?tags=13207-Computer+Vision
    - למשל dataset עבור ספרות שנכתבו בכתב יד: https://www.kaggle.com/datasets/hojjatk/mnist-dataset

הרשמה בטבלת המטלה (קישור מופיע במודל)

- ניתן להגיש את העבודה בין ביחידים או בקבוצות של עד 4 סטודנטים (5 אם המטלה כוללת סטודנט/ית במילואים).
- יש להירשם באקסל המשותף את הפרטים הבאים:
  - **Assignment type** (סוג המטלה) – ניתוח טקסט / עיבוד תמונה
  - **Learning type** (סוג הלמידה) – יש למלא classification, regression או clustering
  - **Implemented Learning algorithms** – שם האלגוריתם שהחלטתם לממש.
  - **Dataset Name** – יש למלא את שם ה- dataset, כפי שמופיע ב- Kaggle.
  - **Dataset URL** – יש למלא את הקישור ל- dataset ב- Kaggle.
  - **Video URL** – יש למלא את הקישור לסרטון ההסבר של המטלה (יש לוודא הרשאות צפיה, לכל מי שיש לו קישור). הקישור ל- YouTube או לכל מקום אחר בו ניתן לצפות בסרטון (ללא הרדה של הסרטון)
  - **Repository URL** – יש למלא את הקישור ל-repository בו העליתם את המטלה, אשר ניתן לצפות במטלה (יש לוודא הרשאות צפיה, לכל מי שיש לו קישור), ללא הורדה שלה וניתן לצפות גם בתוצאות ההרצה (ההרצה של המטלה היא על אחריותכם).
  - **פרטי הסטודנטים -**
    - **Contact emails**: פרטי הקשר של הסטודנטים, **רק אם הם שונים מהמייל במודל**. יש להפריד ע"י פסיק (,) במידה ויש יותר ממייל אחד.
    - **Student name x** – יש לכתוב את השם בעברית כפי שמופיע מודל (בעמודות student name 1, student name 2, student name 3, student name 4, ו- student name 5)
    - **Email student x** – **יש לכתוב את המייל כפי שמופיע במודל** (בעמודות email student 1, email student 2, email student 3, email student 4, ו- email student 5)

הסכמה להראות תוצרים

סמנו V אם אתם מוכנים שנפרסם את סרטון המטלה במודל לסטודנטים אחרים. הסכמה לפרסום – **<u>תזכה ב-5 נקודות בונוס</u>**

תאריך הגשת המטלה

את המטלה יש להגיש עד יום ראשון בערב ה- 24.5 הגשה באיחור עד יום ראשון בערב, ה- 31.5 ל (קנס סימלי של חצי נקודה ליום על הגשה באיחור).

בונוס על הגשה מוקדמת

יינתן **בונוס של 0.5 נקודה, עבור כל יום לפני** היום המופיע כתאריך הגשה בזמן בהמשך (24.5).

תוצרי ההגשה

התוצרים ישלחו בקישורים (כפי שמתואר בהמשך)

- הקישורים צריכים להיות זהים הן בהגשה אצל כל הסטודנטים בקבוצה והן בקובץ ההרשמה
- **<u>יש לבדוק את תקינות כל אחד מהקישורים מבחינת הגישה ומבחינת עדכניות התוכן</u>**
  - וודאו שישנה גישה לכל אחד מהקישורים, עבור כל מי שקיבל את הקישור.

סרטון הצגת המטלה

- מירב הערכה של המטלה תתקיים מול הסרטון שתכינו.
- **על הסרטון להיות באורך של כ 4-5 דקות (לא יותר)**
- בהצגת המטלה, עליכם להציג את הדברים, בהנחה שמי שצופה בסרטון אינו יודע את החומר.
- בתחילת הסרטון, עליכם להציג את הסטודנטים בקבוצה.
- **עליכם להציג את החלקים השונים במטלה ואת התוצרים שלה**, כשאתם מראים את הקוד ואת הפלט ומלווים אותו בהסברים, שמראים הבנה של מה שעשיתם ושל התוצאות.

- אנחנו מצפים מכם לשתף את כל חברי הקבוצה בסרטון, במידה שווה ככל האפשר.
- המיקוד בסרטון הוא של הקוד והתוצרים ואין צורך להראות את חברי הצוות.
- אי הגשת סרטון, או סרטון לא זמין או לא תקין, תגרור קנס משמעותי בציון.
- **לסיכום**: **חובה** לשלוח קישור לסרטון ברור, מקיף וכולל שמראה וסוקר את העבודה שלכם ואת התוצרים באופן מקיף וברור ומראה **שהבנתם אותם** והם פועלים כראוי.
- **מטלה ללא הגשת קישור תקין לסרטון, תיקנס ב30 נקודות**

מחברת הקוד

- **התוכן הכלול במטלה מוסבר בסעיף *פרטי המטלה* בהמשך**.
- וודאו שישנה גישה לסרטון לכל מי שקיבל את הקישור.
- על המחברת לכלול גם את התוצרים והויזואליזציות, ללא הורדה והרצה במחשב של מי שיבדוק אותה.
- על המחברת להיות מלווה בהערות והסברים קצרים שמסבירים את העבודה והתוצרים.
- שימו לב – ההערכה במטלה היא בעיקרה על התהליך ולא על התוצאות בשערוך איכות המודל.
- אי הגשת מחברת הפתרון, או הגשת מחברת הפתרון לא זמינה או לא תקינה, תגרור קנס משמעותי בציון.
- **לסיכום**: **חובה** לשלוח **קישור** מחברת מטלה ברורה, מקיף וכולל שמראה וסוקר את העבודה שלכם ואת התוצרים באופן מקיף וברור.
- **מטלה ללא הגשת קישור תקין לקוד, תיקנס ב30 נקודות**
- **מטלה ללא הגשת קישור תקין לקוד ולסרטון לא תיבדק ותקבל 0 וחבל**

אופן ההגשה

- נבסס את ההגשה על אקסל ההרשמה והנתונים הבאים הינם לצורך גיבוי.

כל סטודנט/סטודנטית בקבוצה ירשום בהגשה את הקישורים הבאים (עם הפרדה של רווח ביניהם), ללא טקסט נוסף.

- ההגשה באופן המתואר להן, הינה לצורך גיבוי. המטלה תיבדק רק פעם אחת לכולם.
- **יש לבדוק את תקינות כל אחד מהקישורים מבחינת הגישה ומבחינת עדכניות התוכן**

דוגמא להגשה דרך הקישור במודל (הקישורים צריכים להיות זהים אצל כל הסטודנטים בקבוצה):

https://youtu.be/kqtD5dpn9C8 https://git.new/FF6Dp2F https://tinyurl.com/bdezpa8x 123456432 76545674 987654356

1. **קישור לסרטון** (תצטרכו להעלות את הסרטון ל- YouTube, או למקום אחר ברשת, בו ניתן לצפות בסרטון) בו אתם מציגים ומסבירים את עבודתכם ואת התוצאות.
   - בדוגמא מופיע כ- https://youtu.be/kqtD5dpn9C8
     - שימו לב, הסרטון צריך להיות תקין וזמין לצפייה ללא צורך בהורדה.
2. **קישור למחברת הקוד שיפתח בדף ה-GitHub / Colab / Azure** של אחד המשתתפים, הכולל, את פרטי הסטודנטים המקוצרים, עזרה בה השתמשתם ב- Chatbot AIהמימוש, ההרצה וההערות.
   - בדוגמא מופיע כ- https://git.new/FF6Dp2F
     - שימו לב, הקוד ב- code repository, צריך לכלול הסברים ופלט של הריצה לשלבים השונים ללא צורך בהורדה.
3. **הקישור ל- dataset ב- Kaggle** - יש להוסיף את הקישור ל- dataset.
   - בדוגמא מופיע כ- https://tinyurl.com/bdezpa8x
     - שימו לב, הסרטון צריך להיות תקין וזמין לצפייה ללא צורך בהורדה.
4. **מספרי ת.ז.** של המגישים עם רווח ביניהם.
   - בדוגמא מופיע כ- 123456432 76545674 987654356
   - בדוגמא ישנם מספרי ת.ז. של 3 מגישים

מה עליכם לבצע במטלה?

על המטלה להפעיל flow של למידה מונחית (למידת סיווג או למידת רגרסיה, לפי בחירתכם, כתלות ב-dataset).

- יש להסביר את כל השלבים אותם אתם עושים בסרטון, כאשר אתם מציגים את הקוד אותו תעלו ל- GitHub / Colab / Azure (או ה- repository) של אחד המשתתפים
- הניקוד יכלול גם הסבר ברור, שמראה שהבנתם מה שעשיתם

חלק 1 – הקדמה, בתחילת המטלה (ניתן לצבור עד 15 נקודות בסעיף זה)

הסעיף כולל את החלקים הבאים: פרטי הסטודנטים, פרומפטים, הסבר על ה- dataset, טעינת ה- dataset

- **פרטי הסטודנט** – בתחילת המטלה, יהיה עליכם לרשום את השם הפרטי והאות הראשונה של שם המשפחה ובנוסף 4 ספרות אחרונות של ת.ז.
  - בהצגה בסרטון, יש להציג בהתחלה את שמות המשתתפים בברור
- **פרומפטים ב AI LLM או צ'ט בוטים, עזרים נוספים** יש להקדיש תא בו תכתבו את ה-prompt בו השתמשתם ב- AI chatbot, קישורים נוספים בהם נעזרתם ומה הייתה המטרה של השימוש בהם – הדבר מותר, אך כמובן שעליכם להראות הבנה
  - **אנחנו מצפים שגם תהיה לכך התייחסות גם בעל פה.**
- **הסבר על בעיית הלמידה וה-dataset** – נדרש סיכום קצר של הבעיה וה- dataset בתחילת קובץ ההגשה באורך של פסקה. עליכם להסביר בצורה קצת יותר מפורטת על כך בע"פ בסרטון.
- **טעינה ה- dataset** (5 נקודות) - על המטלה לכלול טעינת ה- trainset וה- test-set
  - שימו לב – אין לחלק את ה-datasets הללו שוב ל- train ו- test.
  - עליכם להציג את 5 השורות הראשונות של כל dataset

מדד האיכות

- **מדדי האיכות הבאים ישמשו גם לשערוך איכות העבודה וגם להשוואה בהתנסות במאפיינים שונים, בסעיפי שערוך האיכות והבונוס בהמשך (סעיפים 5 ו-6)**
- בבעיות רגרסיה – האיכות תוערך לפי מדד r^2.
- בבעיות סיווג multi-class (או עם 2 מחלקות, אך ללא מחלקה מרכזית) – macro-average-f1
- בבעיית סיווג בינארית (עם מחלקה מרכזית אחת בלבד) – f1 (רק על המחלקה המרכזית)

חלק 2 – feature engineering (ניתן לצבור עד 30 נקודות בסעיף זה)

- מטריקות שיש להתנסות בהם, הינם מטריקות אותם למדנו עבור ניתוח טקסט או עיבוד תמונה
- אם ברצונכם להפעיל feature engineering נוסף, בצעו זאת במסגרת ההרחבה, המתוארת בסעיף 5.
- יש להציג את ה- feature engineering על 2-3 דוגמאות ב- train וב-test

חלק 3 – מימוש אלגוריתם למידה (ניתן לצבור עד 30 נקודות בסעיף זה)

- עליכם לממש אלגוריתם למידה אליו נרשמתם.
- מצופה לממש אלגוריתם שנלמד בשבועיים האחרונים ביחס לתאריך ההגשה.
  - למשל אם למדנו KNN, ואתם מגישים חודש אחרי (חופשות, אינם נכללים בחישוב החודש), ממשו אלגוריתם יותר עדכני.
  - בונוס של עד 5 נקודות, עבור אלגוריתם מסובכים יחסית (לשקול המרצים), כמו ANN.
- עליכם לאפשר שימוש ב- hyperparameters שונים – לכל הפחות כפי שנלמד בכיתה
- עליכם לאפשר פונקציה של אימון ופונקציה של predict
- עליכם לעבור על האלגוריתם ולהסביר אותו

חלק 4 – אימון - הפעלת ה- flow לפי הפרמטרים השונים (ניתן לצבור עד 10 נקודות בסעיף זה)

- אם בחרתם להתנסות בהרחבות (סעיף 6), עליכם להשתמש בקומביציה המוצלחת עבור כל ה- trainset (כלומר לאמן מחדש), עליכם להציג את התהליך שכמה דוגמאות (2-3 דוגמאות) עוברות במהלך ה- feature engineering.

חלק 5 – חיזוי ושערוך איכות המודל על ה- test set (ניתן לצבור עד 10 נקודות בסעיף זה)

- אם בחרתם להתנסות בהרחבות (סעיף 6), עליכם להשתמש בקומביציה המוצלחת עבור כל ה- test-set, עליכם להציג את התהליך שכמה דוגמאות (2-3 דוגמאות) עוברות במהלך ה- feature engineering.
- יש להראות את תוצאות חיזוי 5 הסיווגים הראשונים על ה- test
- יש להראות את איכות המודל כמתואר לעיל (ובעזרת השיטה המיוחדת לשיערוך איכות, אם בחרתם לבצע הרחבה כזו).

חלק 6 – הרחבה – סעיף בונוסים (ניתן לצבור עד 65 נקודות בסעיף זה)

6.א. ניהול הניסויים עם grid-search k-fold cross-validation (ניתן לצבור עד 5 נקודות בתת-סעיף זה)

- **grid-search**
  - עליכם לבצע grid-search, בו תבחנו את כל הפרמוטציות. כלומר, מכפלה קרטזית של הפרמוטציות של feature engineering, המודלים השונים שנוצרים ע"י אלגוריתמי הלמידה אותם בחרתם עם ה-hyperparameters השונים.
- **K-fold cross validation**
  - 5-fold cross validation שיעטוף את כל החלקים בניסויים. יש לחלק את ה-trainset ל-5 חלקים שווים ובכל פעם משתמשים ב-4 חלקים לאימון ו-1 ל-validation, תבצעו כל פרמוטציה מה- grid search 5 פעמים (1 לכל fold) ותבחנו את המדד על ה- חלק הנוסף (validation). עליכם לחשב מדד ממוצע המדד ל-5 ה- folds לכל פרמוטציה.
  - את ההרחבות המתוארות בהמשך, יש לבצע בעזרת k-fold cross validation grid search, המתואר לעיל, בסעיף זה.
- **ניקוד**
  - <u>עד 5</u> נקודות על מימוש ה- k-fold cross validation grid search
  - <u>עד 2</u> נקודות, על שימוש נכון k-fold cross validation grid search שכבר מומש (למשל של scikit-learn).

6.ב. התנסות ב- feature engineering (ניתן לצבור עד 20 נקודות בתת-סעיף זה)

- יש להתנסות בערכים שונים של feature engineering הנבחר.
- אם רוצים להתנסות feature engineering שלא נלמד בכיתה, יש לבצע זאת בנוסף feature engineering שנלמד בכיתה ולבצע חלק מההשוואה לעומת ה- feature engineering שנלמד בכיתה.
  - במקרה זה, עליכם להרחיב את ההסבר ב- feature engineering שלא נלמד בכיתה
  - תוכלו בנוסף להתנסות באפשרויות שונות של אותו feature engineering
- מצופה לבצע עיבוד מוקדם ייעודי ומיוחד הדרוש לבעיה הספציפית, ל- dataset ולסוג האפליקציה
- אם בחרתם להתנסות גם ב- hyper parameter שונים, הוספו אותם למכפלה הקרטזית שתיבדק
- יש להציג את ההתנסויות השונות ב- dataframe – ולהציג את ממוצע הציון ב- cross validation כמוזכר בסעיף 3.א.
- הציגו את ההרחבה במחברת הקוד ובעל פה
- **ניקוד התנסות ב- feature engineering**
  - <u>עד 5</u> נקודות על מימוש התנסות בכל אחת מה- feature engineering (ניתן להגיע ל- 20 נקודות לכל היותר, בסעיף זה)

6.ג. התנסות ב- hyper parameters (ניתן לצבור עד 10 נקודות בתת-סעיף זה)

- יש להתנסות בערכים שונים של hyperparameters נבחרים.
- אם רוצים להוסיף hyper parameter שלא נלמד בכיתה, עליכם להרחיב ולהסביר אותו יותר
- אם בחרתם להתנסות בכמה hyperparameters, צריך לאסוף את כל הפרמוטציות האפשריות בין ה-hyperparameters וערכיהם השונים
- אם בחרתם להתנסות גם ב- feature engineering שונים, הוספו אותם למכפלה הקרטזית שתיבדק
- יש להציג את ההתנסויות השונות ב- dataframe – ולהציג את ממוצע הציון ב- cross validation כמוזכר בסעיף 3.א.
- הציגו את ההרחבה במחברת הקוד ובעל פה
- **ניקוד התנסות ב- hyperparameters**
  - <u>עד 5</u> נקודות על מימוש התנסות בכל אחת מה- hyperparameters ניתן להגיע ל- 10 נקודות לכל היותר, בסעיף זה)

6.ד. הרחבות נוספות - התאמות מיוחדות של ה- data (ניתן לצבור עד 10 נקודות בתת-סעיף זה)

- **<u>התאמות מיוחדות של ה- data</u>**– התאמות המיוחדות של ה- data הדרושות לבעיה הספציפית, ל-dataset ולסוג האפליקציה, טיפולים שונים ב- imbalanced data שמבוססות בעיקר על under-sampling, over-sampling, וייצור של דוגמאות סינטטיות.
- הציגו את ההרחבה במחברת הקוד ובעל פה
- **<u>ניקוד עבור הרחבה זו</u>** <u>עד 10 נקודות</u>

6.ה. הרחבות נוספות - בדיקת איכות מיוחדת (ניתן לצבור עד 5 נקודות בתת-סעיף זה)

- בדיקת איכות ספציפית ומיוחדת **<u>נוספת</u>** הדרושה לבעיה הספציפית, ל- dataset ולסוג האפליקציה, **<u>בנוסף למדדים המתוארים לעיל</u>** כמו למשל Intersection over Union (IoU) לבעיות localization בראיה ממוחשבת או BLEU Score לאפליקציות תרגום ב-NLP.
- הציגו את ההרחבה במחברת הקוד ובעל פה
- **<u>ניקוד עבור הרחבה זו</u>** <u>עד 5 נקודות</u>

6.ו. הרחבות נוספות - Explainability - הבנת התוצאות, הנגשתם והנגשת המאפיינים (ניתן לצבור עד 10 נקודות בתת-סעיף זה)

- הבנה וניתוח של הנתונים החשובים, בעזרת טכניקות המוטמעות במידע שמוחזק כתוצאה מהלמידה, שמוחזר עם המודל עם החיזוי, או בטכניקות שונות שמנתחות את החיזויים והמאפיינים לאחר החיזוי, כמו SHAP.
- הציגו את ההרחבה במחברת הקוד ובעל פה
- **<u>ניקוד עבור הרחבה זו</u>** <u>עד 10 נקודות</u>

6.ז. הצגת הניסויים (ניתן לצבור עד 5 נקודות בתת-סעיף זה)

- **הצגת כל הפרמוטציות והתוצאות (הממוצעות) של המדד ב- dataframe**
- **הציגו את הפרמוטציה הטובה ביותר עם ציון הפרמוטציה הטובה ביותר**.
- <u>בהמשך בשלב האימון (סעיף 4)</u> – **עליכם לאמן את כל ה- trainset עם הפרמוטציה המוצלחת ביותר**
- <u>בשלב הבדיקות, test (סעיף 5)</u> **– עליכם לבצע את אותו preprocessing גם על דוגמאות ה- test.**

6.ח. בונוס על הגשה מוקדמת

שימו לב, שיינתן גם בונוס על הגשה מוקדמת, כמפורט לעיל בסעיף "תאריך הגשת המטלה" בעמוד 2

6.ט. בונוס על הסכמה לשיתוף

שימו לב, שיינתן גם בונוס על הסכמה לשיתוף, כמפורט לעיל בסעיף "הסכמה להראות תוצרים" בעמוד 2